

Semantic Sensitivities and Inconsistent Predictions: Measuring the Fragility of NLI Models (EACL 2024)

מטרת המאמר

המאמר בודק עד כמה מודלי *NLI* (משימה שבה המודל מקבל שני משפטים, וצריך לקבוע מה היחס הלוגי ביניהם - האם המשפט השני נכון בהכרח לפי הראשון, סותר אותו, או שאין ביניהם מספיק קשר כדי להסיק משהו), באמת מבינים משמעות סמנטית, או פשוט מסתמכים על דפוסים שטחיים בטקסט.

הטענה המרכזית:

גם מודלי ה-Transformer החזקים מאוד משנים תחזיות בעקבות שינויי ניסוח קטנים שלא משנים את המשמעות בפועל.

הבעיה שהמאמר מזהה

מודלי *NLI* מציגים ביצועים גבוהים בדאטהסטים רגילים, ולכן בני האדם לעיתים מסיקים שיש להם "הבנה סמנטית".

עם זאת, המאמר טוען שזה מטעה. המודלים רגישים ל:

- שינויי ניסוח קטנים
- החלפת מילים דומות
- שינוי מבנה המשפט
- וריאציות שטחיות

גם כאשר המשמעות נשמרת לחלוטין.

כלומר - המודל נותן תחזיות לא עקביות עבור משפטים שאמורים להיות שקולים במשמעות.

הרחבה על "מה זה *NLI*"

ב-*NLI* המודל מקבל:

- Premise** - משפט בסיס / עובדה נתונה.
- Hypothesis** - משפט נוסף שצריך לבדוק מולו.

המודל צריך לבחור אחת משלוש תשובות:

- Entailment** - המשפט השני נובע מהראשון.
 - כלומר: אם הראשון נכון, השני חייב להיות נכון.
- Contradiction** - המשפט השני סותר את הראשון.
 - כלומר: אם הראשון נכון, השני לא יכול להיות נכון.
- Neutral** - אין מספיק מידע.
 - כלומר: המשפט השני לא נובע מהראשון, אבל גם לא סותר אותו.

הרעיון המרכזי של המאמר

החוקרים (מחברי המאמר) יוצרים וריאציות חדשות למשפטים קיימים. **כאלו המנוסחות אחרת, אך שומרות על אותה המשמעות.** ולאחר מכן בודקים - האם מודל ה- *NLI* משנה את התחזית שלו. **אם כן - זה מעיד על *Semantic Sensitivity* (רגישות לשינויים קטנים בניסוח, גם כשהמשמעות לא השתנתה).**

וריאציות למשפטים

החוקרים השתמשו ב- LLM כדי לבצע Paraphrasing (ניסוח מחדש של אותו משפט במילים אחרות).

דוגמה פשוטה :

- **Original**
 - My name is Danny and I love ice cream.
- **Variation:**
 - I'm Danny, and I like ice cream

דוגמה מהמאמר :

- **Original**
 - Sweat built up upon his face.
- **Variation:**
 - The sweat had built up on his face.

לאחר היצירה, הם בודקים שהמשמעות באמת נשמרה. **הם עושים זאת באמצעות תנאי - המודל צריך לזהות שהמשפט המקורי והמשפט החדש גוררים זה את זה הדדית.** מונח הנקרא *Symmetric Entailment* (כל משפט נובע מהשני, כלומר שניהם שקולים במשמעות).

מתודולוגיה

1. **שלב 1 -** לוקחים רק דוגמאות שמודל ה- *NLI* ענה עליהן נכון מלכתחילה.
 - a. **המטרה -** לוודא שהבדיקה מודדת רגישות סמנטית, ולא סתם טעויות רגילות של המודל.
 - b. **לדוגמה :**
 - i. **Premise -** Danny is eating ice cream
 - ii. **Hypothesis -** Danny is Eating dessert
 - iii. **Prediction -** Entailment (שקולים)

2. **שלב 2 -** מייצרים 5 וריאציות סמנטיות לכל Hypothesis. תהליך הנקרא **Paraphrasing**.
 - a. **לדוגמה :**
 - i. Danny is having a sweet dish.

3. **שלב 3 -** מחליפים את ה- *Hypothesis* המקורי בגרסה החדשה.
 - a. **לדוגמה :**
 - i. **Original Premise -** Danny is eating ice cream
 - ii. **New Hypothesis (After Paraphrasing) -** Danny is Eating dessert

4. **שלב 4 -** מריצים שוב את בדיקת מודל ה- *NLI*, במטרה לבדוק האם הוא מזהה שגם הווריאנט החדש הוא *Symmetric Entailment*.

מודלים שנבדקו

המאמר בודק מספר מודלים מבוססי Transformer, כגון:

- **RoBERTa**
- **BART**
- **DeBERTa**
- **DistilBART**

כולל גרסאות של אותו המודל בגדלים שונים.

דאטה סטים

- **MNLI**, Multi-Genre Natural Language Inference
 - אוסף גדול של זוגות משפטים ממספר תחומים שונים, המשמש לבדיקת הבנת השפה
- **SNLI**, Stanford Natural Language Inference
 - אחד מדאטה דאטה סטים הראשונים והנפוצים ביותר לתחומי ה-NLI
- **ANLI**, Adversarial NLI
 - דאטה סט הנחשב כקשה, הנבנה במיוחד למציאת נקודות חולשה במודלי NLI.

מדדי הערכה מרכזיים

- **Relaxed Fooling Rate**
 - כמה פעמים שינוי ניסוח גרם לשינוי כלשהו בתחזיות (לא משנה מה התחזית הסופית בשלב 4, אם היא טעות אז המדד לוקח אותה בחשבון).
- **Strict Fooling Rate**
 - תת מדד של Relaxed fooling rate, המודד (סופר) רק מקרים קיצוניים בהם התחזית התהפכה לחלוטין, משמע מ- Entailment בשלב 1, ל- Contradiction בשלב 4

תוצאות מרכזיות

- **ב - In-Domain** (בדיקה על דאטה דומה לזה שעליו המודל אומן)
 - נרשמה ירידה ממוצעת של **12.92%** במדד ה- Relaxed Fooling Rate
 - **ב - Out-of-Domain** (בדיקה על סוג דאטה שונה ממה שהמודל ראה בזמן האימון)
 - נרשמה ירידה ממוצעת של **23.71%** במדד ה- Relaxed Fooling Rate
- כלומר -** אפילו שינויי ניסוח קטנים גורמים לפגיעה משמעותית בביצועים.
- בחלק גדול מהמקרים - המודל לא רק שינה את תשובתו, אלא עובר ממש לקטגוריה ההפוכה לוגית. משמע, גם מדד ה- Strict Fooling המחמיר היה גבוה מאוד.
- החוקרים ראו בכך סימן לכך שהמודלים לא באמת שומרים על עקביות סמנטית.**

ממצאים נוספים

- מודלים קטנים יותר רגישים יותר לשינויים.
- **Distilled Models** (מודלים "מכווצים", גרסאות קטנות ומהירות יותר של מודלים גדולים) מאבדים יותר יציבות סמנטית.
- גם מודלים גדולים מאוד עדיין סובלים מבעיית חוסר העקביות הסמנטית (*Semantic Sensitivity*)
- הבעיה חמורה יותר ב- **Zero-Shot** (מצב שבו המודל נבחן על סוג משימה או דאטה מבלי שעבר עליו תהליך *Fine Tuning*)

מסקנות המאמר

- ביצועים גבוהים על Benchmarks (מבחן סטנדרטי מקובל בתחום) לא מוכיחים הבנה סמנטית אמיתית.
- המודלים:
 - רגישים לשינויי ניסוח קטנים
 - מתקשים לשמור על עקביות
 - לא באמת מבינים Compositional Semantics (הבנת משמעות דרך התחביר והמבנה של חלקי המשפט)

תרומת המאמר

התרומה העיקרית אינה מודל חדש, אלא Framework חדש (שיטת בדיקה מסודרת) למדידת Semantic Sensitivity במודלי NLI.

מגבלות שהחוקרים ציינו

- הבדיקה נעשתה רק באנגלית.
- התמקדו בעיקר ב – NLI.
- לא נבדקו LLMs גדולים מאוד (כמו GPT 4.0)
- ניתן להרחיב את השיטה למשימות NLP נוספות.

חשיבות המאמר

המאמר מציג את הפער בין:

- המודל מצליח במשימה

לבין:

- המודל באמת מבין שפה

זה מתחבר לדיון רחב בעולם ה – NLP : האם מודלי שפה באמת מבינים משמעות, או רק מזהים דפוסים סטטיסטיים בטקסט.