

A Large Annotated Corpus for Learning Natural Language Inference

הרעיון המרכזי

המאמר מציג את SNLI (Stanford Natural Language Inference), אחד ה-datasets הראשונים והמשמעותיים ביותר בתחום ה-NLI. **המטרה** - ליצור corpus גדול ואיכותי, שיאפשר לאמן מודלים עמוקים (Deep Learning Models) על משימת inference בשפה טבעית.

הבעיה לפני SNLI

- לפני SNLI, רוב datasets של NLI היו:
 - קטנים מאוד
 - עם מעט דוגמאות
 - לרוב generated automatically
- ולכן - היה קשה לאמן neural networks בצורה טובה.

התרומה המרכזית

SNLI כלל:

- מעל 570K זוגות של מילים
- Annotations אנושיים
- balanced classes
- entailment / contradiction / neutral
- זה היה dataset עצום ביחס למה שהיה קיים אז.

איך יצרו את הדאטה

החוקרים השתמשו בתיאורי תמונות (Image Captions). הם קיבלו תמונה, והתבקשו לכתוב:

- משפט שבהכרח נכון (entailment)
- משפט שאולי נכון, אך חסר מידע (neutral)
- משפט שבהכרח לא נכון (contradiction)

המטרה הייתה - להקטין ambiguity (עמימות במשמעות). **כלומר** - כשכולם מדמיינים את אותה סצנה, יותר קל לקבוע האם משפטים באמת סותרים או תואמים.

הממצאים המרכזיים

datasets גדולים מאפשרים לאמן neural networks טובים יותר. אך חשוב לציין, שלמרות החשיבות העצומה שלו, כיום הדאטה סט נחשב כפשוט יחסית. והמשפטים בו לא כללו reasoning מורכב.