

A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference

הרעיון המרכזי

המאמר מציג dataset חדש בשם MultiNLI (Multi-Genre Natural Language Inference) **המטרה** - ליצור benchmark קשה ומגוון יותר עבור NLI, שיבדוק understanding אמיתי של שפה טבעית, ולא רק הצלחה על משפטים פשוטים. המאמר נכתב בעקבות מגבלות של SNLI (Stanford Natural Language Inference), שהיה dataset פופולרי מאוד, אך פשוט יחסית.

הבעיה ב - SNLI

SNLI התבסס בעיקר על image captions (תיאורי תמונות פשוטים). ולכן:

- המשפטים היו קצרים ופשוטים
 - כמעט לא הופיעו phenomena מורכבים
 - המודלים התחילו להגיע ל – accuracy גבוה מאוד
- כלומר – SNLI כבר לא היה benchmark מספיק מאתגר.

התרומה המרכזית

החוקרים בנו dataset חדש (MultiNLI) הכולל:

- 433K examples
- 10 ז'אנרים שונים
- גם טקסט כתוב וגם שפה מדוברת

המטרה - לבדוק האם מודלים באמת יודעים לבצע - Natural Language Understanding

החידוש החשוב ביותר

בניגוד ל – SNLI, המאמר בודק גם - Cross-Domain Generalization כלומר - האם מודל שאומן על סוג טקסט אחד, מצליח להבין גם סוגי טקסט אחרים.

Matched vs Mismatched

- **Matched** - בדיקה על genres שהמודל ראה בזמן האימון
 - במאמר ה anchor, זה נקרא in-Domain
- **Mismatched** - בדיקה על genres חדשים לחלוטין
 - במאמר ה anchor, זה נקרא out-of-domain

ממצאים מרכזיים

- כל המודלים ירדו משמעותית בביצועים לעומת ביצועיהם ב SNLI
- גם מודלים חזקים כמו ESIM (Enhanced Sequential Inference Model) התקשו להגיע ל – accuracy גבוה.
- המאמר הראה שמודלים מתקשים במיוחד עם:
 - שלילה (Negation)
 - משפטים כמותיים (Quantifiers)
 - סימני שיח (discourse markers) – anyway, by the way, so, furthermore, in addition,
 - however, וכדומה
 - השוואות comparatives
 - פעלי דעה ואמונה (belief verbs) – believe, Think, Assume, know, suspect.....

כלומר - ככל שהשפה יותר מורכבת, המודלים מתקשים יותר.