

Adversarial NLI: A New Benchmark for Natural Language Understanding

הרעיון המרכזי

המאמר מנסה לענות על בעיה קריטית בעולם ה-NLU, מודלים מגיעים לציונים גבוהים על benchmarks, אבל בפועל:

- לא באמת מבינים שפה
- לומדים קיצורי דרך יוריסטיים
- מנצלים biases סטטיסטיים בדאטה

חוקרי המאמר טענו כי ה-benchmarks הסטטיים "נשברים" מהר מדי, כי המודלים לומדים את הטריקים של הדאטה.

הרעיון החדש Adversarial Data Collection

במקום לאסוף דאטה רגילה, הם עשו: Human-And-Model-in-the-Loop (HAMLET) כלומר, בני אדם ניסו בכוונה "להפיל" את המודל.

אופן הפעולה:

1. אימנו מודל NLI על דאטה מתאימה (לדוגמה, על SNLI)
 2. לאחר האימון, הנבדק קיבל:
 - a. **Context** (Premise)
 - b. **Target Label** (contradiction / entailment / neutral)
 3. המשתתף האנושי כתב Hypothesis, כך שבינה לבין ה-Premise יש קשר של Target Label
 4. שלחו את (Premise, Hypothesis) למודל ה-NLI, וקיבלו את תוצאת הסיווג שלו.
 - a. אם המודל צדק – הדוגמה (premise, Hypothesis) לא נכנסה לדאטהסט, ועוברים לדוגמה חדשה.
 - b. אם המודל טעה – הדוגמה עוברת verification אנושי נוסף. במטרה לוודא שאין בעיה לוגית בהיפותזה, שגרמה למודל ה-NLI לטעות (וידאו שאין Bias).
 - i. בהנחה וה-Hypothesis עברה את ה-Verification - הדוגמאות החדשות שהמודל טעה בהן מתווספות ל-training set שעליו המודל התאמן בשלב 1
 5. חוזרים לשלב 1 עם ה-Training Set המעודכן.
 - a. חוזרים על התהליך באופן איטרטיבי – במחקר ביצעו זאת ב-3 איטרציות.
- המטרה -** לייצר benchmark "עיוני" (Adversarial) שמתפתח יחד עם המודלים, ולא נשאר סטטי. כזה שנבנה במיוחד כדי לחשוף את החולשות האמיתיות של מודלי ה-NLI

למה זה חשוב

- בדאטה רגיל - המודל רואה patterns קבועים.
- בדאטה עיוני (Adversarial) – בני האדם מחפשים חולשות, יוריסטיקות, קיצורי דרך, הטיות. ולכן, המודל חייב להבין טוב יותר, ולא רק "לנחש".

ממצאי המאמר

מודלים שנבחנו, כמו BERT, RoBERTa, XLNet – הצליחו על דאטה סטטית "רגילה" (כמו SNLI, MNLI, GLUE), אך **נפלו באופן משמעותי** על הדאטה של ANLI. החוקרים זיהו מספר סוגי reasoning - language phenomena (תופעות שפה) שגרמו למודלים להיות שבירים במיוחד:

- **numerical reasoning** - reasoning המבוסס על מספרים וכמויות.
לדוגמה
○ "less than 5" למול "more than 10"
- **Negation** - שימוש בשלילה שמשנה את משמעות המשפט.
לדוגמה
○ "He is running" למול "He is not running"
- **lexical tricks** - ניסוחים מבלבלים המבוססים על מילים דומות או patterns שטחיים.
- **Presuppositions** - מידע שמונח כ"ברור מאליו" בתוך המשפט.
לדוגמה:
○ "The king stopped smoking" ← מניח שהמלך עישן בעבר.
- **Coreference** - הבנה למי מתייחס כינוי גוף.
לדוגמה:
○ "Dan told Tom that he won."
- **word overlap traps** - משפטים עם מילים משותפות רבות, אך משמעות שונה או סותרת.
- **commonsense reasoning** - צורך בידע עולם בסיסי והיגיון אנושי.
לדוגמה
○ אם משיהו נרטב בגשם, אז כנראה ירד גשם.
- **Ambiguity** - עמימות במשמעות המשפט.
- **pragmatic reasoning** - הבנת משמעות לפי הקשר וכוונת הדובר, ולא רק לפי המילים עצמן.

לסיכום, המאמר מראה ש:

High benchmark score $\neq$ Real language understanding

וזו אחת הטענות המרכזיות ביותר בעולם ה- NLU המודרני.