

Right for the Wrong Reasons: Diagnosing Syntactic Heuristics in Natural Language Inference

הרעיון המרכזי

המאמר טוען שמודלי NLI מצליחים מאוד על benchmarks, אבל לעיתים בגלל "טריקים" סטטיסטיים פשוטים, ולא בגלל הבנה אמיתית של תחביר ומשמעות.

החוקרים בודקים האם המודלים משתמשים ב- Heuristics (קיצורי דרך פשוטים לקבלת החלטות) במקום reasoning אמיתי.

שלושת ה- Heuristics המרכזיים

1. Lexical Overlap Heuristic

- a. מצב בו המודל מניח - אם רוב המילים במשפט השני מופיעות במשפט הראשון, אז כנראה יש Entailment.
- b. לדוגמה:
 - i. Premise - The actor was paid by the judge.
 - ii. Hypothesis - The actor paid the judge.
 - iii. Prediction - entailment
- c. המודל טועה כי הוא מסתכל בעיקר על חפיפת מילים, ולא באמת מבין את התחביר.

2. Subsequence Heuristic

- a. המודל מניח שכל רצף מילים מתוך המשפט המקורי הוא נכון בפני עצמו.
- b. לדוגמה:
 - i. Premise - The doctor near the actor danced.
 - ii. Hypothesis - The actor danced.
 - iii. Prediction - entailment
- c. לא בהכרח נכון - המודל ראה את ההיפותרזה כ- sub sequence של ה- Premise, והוא הניח שזה עדיין תקף.

3. Constituent Heuristic

- a. המודל מניח שכל חלק תחבירי פנימי במשפט מייצג עובדה נכונה בפני עצמה.
- b. לדוגמה:
 - i. Premise - If the artist slept, the actor ran.
 - ii. Hypothesis - The artist slept.
 - iii. Prediction - entailment
- c. זה לא נובע מהמשפט המקורי - אבל המודל מתבלבל בגלל המבנה התחבירי.

התרומה המרכזית של המאמר

החוקרים יצרו דאטהסט חדש בשם HANS (Heuristic Analysis for NLI Systems) במטרה לבדוק האם מודלי NLI באמת מבינים (inference) או רק משתמשים ב- heuristics שטחיים.

הדאטהסט **בניי בכוונה** ממקרים שבהם ה- heuristics אמורים להיכשל. כלומר - דוגמאות שנראות "דומות" ברמה היוריסטית השטחית, אבל לוגית אינן entailment.

המטרה - לחשוף shortcut learning (למידת קיצורי דרך סטטיסטיים במקום הבנה אמיתית).

המודלים שנבדקו

- DA
 - מודל פשוט המסתכל בעיקר על אילו מילים מופיעות, בלי להבין את הסדר שביניהן
- ESIM
 - מודל מבוסס RNN (מודל סדרתי) שמעבד מילים אחת אחרי השנייה
- SPINN
 - מודל מבוסס עצים, המשתמש במבנה תחבירי של המשפט
- BERT
 - מודל מבוסס טרנספורמר

התוצאות המרכזיות

- **על הדאטה סט של MNLI** - כל המודלים קיבלו ציונים גבוהים מאוד.
- **על הדאטה סט של HANS** - הביצועים קרסו כמעט לחלוטין.
 - **במקרים רבים** - הדיוק היה קרוב ל-0%.
- **כלומר** - המודלים הצליחו על benchmark רגיל, אבל נכשלו ברגע ששברו להם את ה - heuristics.
- אפילו BERT, שנחשב בעיני רבים כ - state-of-the-art, נפל ברוב המקרים.
- זה היה ממצא משמעותי מאוד בתחום, כי הוא הראה שגם מודלים חזקים מאוד :
 - לא באמת מבינים תחביר
 - לא מבצעים reasoning עמוק
 - ומסתמכים על patterns שטחיים.

ניסוי חשוב נוסף

החוקרים הוסיפו examples הדומים לאלו של HANS לתוך ה - training data של המודלים שנבדקו.

לאחר מכן - הביצועים השתפרו משמעותית

המסקנה - הבעיה היא לא רק בארכיטקטורה, אלא גם ב - dataset bias (הטיות בדאטה שגורמות למודל ללמוד shortcuts)

המסר המרכזי של המאמר

High benchmark accuracy $\neq$ Real language understanding.

כלומר - ציונים גבוהים על benchmark לא מוכיחים הבנה אמיתית של שפה .