

Breaking NLI Systems with Sentences that Require Simple Lexical Inferences

הרעיון המרכזי

המאמר בודק האם מודלי NLI באמת יודעים לבצע inference פשוט המבוסס על ידע מילוני (dict) בסיסי. החוקרים מראים שמודלים מצליחים מאוד על הדאטה-סט של SNLI, אבל נכשלים כאשר צריך להבין קשרים לקסיקליים פשוטים כמו:

- מילים נרדפות
- מילים מנוגדות
- קטגוריות
- ידע עולם בסיסי

כלומר - המודלים לא באמת "מבינים" את הקשרים בין המילים.

מתודולוגיה

החוקרים יצרו test set חדש, המבוסס על דוגמאות מתוך ה - SNLI בכל דוגמה - שינו רק מילה אחת במשפט.

לדוגמה:

- A little girl is very sad. - Premise
 - A little girl is very unhappy. - Hypothesis
- כאן צריך להבין ש - sad $\approx$ unhappy , כלומר entailment .

דוגמה נוספת:

- The man is holding a saxophone. - Premise
 - The man is holding an electric guitar - Hypothesis
- כאן צריך להבין ש - sad $\neq$ unhappy , כלומר contradiction .

הרעיון החשוב במתודולוגיה הוא שהחוקרים דאגו שכל המילים:

- כבר הופיעו ב - training data
- כבר קיימות ב - word embeddings
- ושלא מדובר במילים נדירות

וכל זאת במטרה להוכיח שהבעיה אינה חוסר מידע, אלא חוסר של generalization .

סוגי הקשרים הלקסיקליים שנבדקו

- Synonyms - מילים עם משמעות דומה
 - happy $\leftrightarrow$ joyful

- Antonym - מילים עם משמעות הפוכה
 - hot $\leftrightarrow$ cold

- Hypernym - קטגוריה כללית
 - champagne $\rightarrow$ wine

- Co-Hyponyms - שתי מילים מאותה קטגוריה
 - guitar $\leftrightarrow$ saxophone

הממצא המרכזי

למרות שהמשימה החדשה הייתה פשוטה יותר מ - SNLI, הביצועים של המודלים קרסו משמעותית. כלומר - המודלים הצליחו על benchmark רגיל, אבל לא הצליחו לבצע inference מילוני בסיסי.

ממצא חשוב נוסף - הגורם שהכי השפיע על הצלחת המודל היה - האם הוא כבר ראה דוגמאות מאוד דומות בזמן האימון. כלומר - המודלים לא באמת למדו חוקיות כללית, אלא בעיקר memorization (שיננו את דפוס האימון)

המסר המרכזי של המאמר

המאמר הזה הוא אחד השלבים הראשונים בתחום שהראו

High benchmark accuracy $\neq$ Real language understanding.

כלומר, מודלי NLI יכולים להיראות חזקים מאוד - אבל עדיין להיכשל על inference פשוט מאוד, כאשר משנים מעט את הניסוח או מחליפים מילה אחת.