

Probing Natural Language Inference Models through Semantic Fragments

הרעיון המרכזי

המאמר בודק האם מודלי NLI באמת מבינים reasoning לוגי וסמנטי, או שהם בעיקר לומדים patterns שטחיים מתוך datasets כמו SNLI ו-MNLI.

כדי לבדוק זאת, החוקרים מציעים להשתמש ב-Semantic Fragments, datasets סינתטיים ומבוקרים, שכל אחד מהם בודק תופעת reasoning מסוימת בצורה ממוקדת. בניגוד ל-datasets רגילים, כאן החוקרים שולטים ב:

- סוג ההסקה
- המורכבות הלוגית
- סוגי המילים
- מבנה המשפטים
- סוג ה-entailment

המטרה - לבודד תופעת reasoning אחת, ולבודק האם המודל באמת יודע להתמודד איתה.

סוגי ה-reasoning שנבדקו

המאמר בנה 8 סוגים שונים של Semantic Fragment, שבודקים reasoning בסיסי ב-NLI. בין היכולות שנבדקו:

- **Negation** - reasoning עם שלילה.
- **Boolean Reasoning** - reasoning עם AND / OR.
- **Quantifiers** - reasoning עם: all / some / none / every
- **Counting** - reasoning המבוסס על כמויות ומספרים.
- **Conditionals** - reasoning מסוג: "If X then Y"
- **Comparatives** - reasoning של השוואות.
לדוגמה - "John is taller than Mike"
- **Monotonicity Reasoning** - reasoning על החלפת מילים בתוך הקשר לוגי.
לדוגמה:
 - "all dogs" → "all poodles"
 - לא** שקול לוגית ל:
"all dogs" → "all animals"

Monotonicity

אחד הנושאים המרכזיים במאמר.

הרעיון - האם מותר להחליף מילה במילה יותר כללית / יותר ספציפית, מבלי לשבור את המשמעות הלוגית.

לדוגמה:

- "All dogs bark" → "All poodles bark"
 - יכול להיות entailment
- "All dogs bark" → "All animals bark"
 - כנראה שלא בהכרח נכון.

המאמר מראה שמודלי NLI מתקשים מאוד ב-reasoning כזה, למרות שזה reasoning בסיסי יחסית בלוגיקה של שפה טבעית.

המודלים שנבדקו

המאמר בדק כמה מודלי NLI :

- BERTs
- ESIMs
- Decomposable Attention
- ביניהם, נבנו 2 קבוצות של מודלים :
- מודלים שאומנו מאפס על ה - Fragments
- מודלים שכבר אומנו על SNLI / MNLI, ואז אומנו ב - Fine Tuning על ה - Fragments.

הממצא המרכזי

המודלים הצליחו להשיג תוצאות Accuracy טובות על ה SNLI, ועל ה MNLI, אך נכשלו כאשר נבדקו על ה - Fragments.

עם זאת, החוקרים הראו משהו מפתיע - גם כאשר מודלים נכשלו על ה - Fragments, אפשר היה ללמד אותם את היכולות החדשות די מהר, באמצעות fine-tuning קצר.

כלומר - הבעיה היא לא בהכרח capacity של המודל, אלא שה - datasets הרגילים לא מאלצים אותו ללמוד reasoning.

תוצאות המאמר

כאשר אימנו מודלים מאפס רק על ה - Fragments, רוב המודלים הצליחו ללמוד את משימות ה - reasoning עצמן היטב. עם זאת, מודלים אלו לא הצליחו לבצע טוב על benchmarks כלליים כמו SNLI/MNLI, ולכן לא נחשבו פתרון שימושי ל - NLI כללי.

המאמר הציע את **Losses Inoculation**. משמע, לעשות fine-tuning למודל על challenge dataset חדש, אבל בלי לפגוע משמעותית בביצועים שלו על ה - benchmark המקורי.

כלומר, **לא רק**: "האם המודל למד את ה - fragment?"
אלא גם: "האם הוא עדיין טוב ב - SNLI / MNLI?"

BERT הצליח להשתפר מאוד על ה - Fragments, עם ירידה קטנה יחסית בביצועים על MNLI. לעומת זאת, מודלים חלשים יותר:

- איבדו ביצועים
 - או לא הצליחו ללמוד חלק מה - Fragments בכלל.
- במיוחד - Comparatives התגלו כקשים מאוד ללמידה.