

Stress Test Evaluation for Natural Language Inference

הרעיון המרכזי

המאמר טוען ש - accuracy גבוה על datasets כמו SNLI ו - MNLI לא באמת מוכיח שהמודל מבין שפה.

לכן החוקרים מציעים מבחן שנקרא - **Stress Tests** מבחנים שמטרתם לבדוק איך מודלי NLI מתמודדים עם תופעות לשוניות קשות, מבלבלות, או מטעות .

הבעיה שהמאמר מזהה

מודלים מצליחים על benchmarks רגילים, אבל ייתכן שהם פשוט:

- מזהים patterns
- מסתמכים על lexical overlap
- או משתמשים ב - shortcuts סטטיסטיים

במקום לבצע reasoning אמיתי.

מתודולוגיה

הם בנו סדרת Stress Tests אוטומטיים, כאשר כל test בודק חולשה אחרת של המודל. הם חילקו את המבחנים ל - 3 קבוצות:

Competence Tests •

- מבחנים הבודקים האם המודל באמת יודע לבצע reasoning למשל:
- **Antonyms** – בדיקה האם המודל מבין שמילים מסוימות הן הפכים במשמעות.
love ↔ hate ♦
- **numerical reasoning** - בדיקה האם המודל יודע להבין ולהשוות כמויות ומספרים בצורה לוגית.
"less than 5" מול "more than 10". ♦

Distraction Tests •

- מבחנים הבודקים האם המודל נופל בגלל "הסחות דעת" שטחיות. למשל:
- **Overlap** - גבוה בין מילים.
♦ לדגמה, הוספת מילים שלא מוסיפות למשמעות של המשפט (אך גם לא פוגעות בו).
- **מילת שלילה** כמו - not
♦ למשל, במקום לכתוב true, ירשמו not false – במטרה לבחון האם המודל "נלחץ" ממילת השלילה, גם כשאינה משנה את המשמעות.
- **משפט ארוך ומבלבל**

Noise Tests ○

- מבחנים הבודקים robustness לרעש בטקסט. למשל:
- ♦ **שגיאות כתיב**
- ♦ **החלפת אותיות**

הממצא המרכזי

כל המודלים חוו ירידה משמעותית בביצועים על ה - Stress Tests, למרות שהם הצליחו מאוד על דאטה סט ה MNL

ממצא חשוב נוסף - המודלים נטו מאוד לחזות entailment, כאשר היה Lexical Overlap גבוה – גם אם זה היה שגוי לוגית.
זה חיזק את הטענה שהם משתמשים ב - heuristics שטחיים, ולא reasoning אמיתי.

המסר המרכזי של המאמר

מודלי NLI יכולים להיראות חזקים מאוד על benchmarks רגילים, אבל להיכשל ברגע שמפעילים עליהם "מבחני לחץ" שבודקים reasoning אמיתי ו - robustness.