

MERGE: Minimal Expression-Replacement Generalization Test for NLI

הרעיון המרכזי

המאמר בודק - האם מודלי NLI באמת מבינים (reasoning) או שהם נשברים אפילו משינויים קטנים מאוד במשפט.

אבל, בניגוד למאמרים קודמים, **כאן השינויים הם מינימליים במיוחד**.
הם מחליפים רק מילים בודדות, תוך ניסיון לשמור:

- על אותה משמעות לוגית
- על אותו מבנה תחבירי
- על אותו word overlap

כלומר, הם מנסים ליצור את "התנאים הכי קלים שיש" למודל.
ככה שגם בסיטואציות אלו המודל נכשל - כנראה שיש בעיית generalization אמיתית.

MERGE

Minimal Expression-Replacement Generalization Evaluation
כלומר, בדיקת generalization באמצעות החלפה מינימלית של ביטויים.

תהליך יצירת הווריאציות

הם לוקחים זוגות של משפטי NLI (Premise + Hypothesis) **ומחליפים מילים משותפות ביניהם** (shared words).

לדוגמה:

Original •

- The **boy** is sleeping.
- The **boy** is resting.

Variant •

- The **girl** is sleeping.
- The **girl** is resting.

שינויים "פשוטים" מהסוג הזה של MERGE **מבטלים את הטענה שהמודלים נכשלים בגלל שינוי מבנה המשפט**. המטרה היא לבחון את יכולת ה reasoning בצורה הפשוטה ביותר.

בנוסף, חשוב להבהיר – החוקרים התמקדו בשינויים הגיוניים בלבד, במטרה לבודד את בעיית ה – reasoning.

משמע, אם יש משפט - The room is hot.

אז הם יכלו לבצע החלפות הגיוניות בלבד, כמו hot → cold
אבל לא יחליפו hot → banana

כי זה יהרוס את ההיגיון והתחביר.

מדד הערכה PA

החוקרים הציעו מדד הנקרא Pattern Accuracy (PA). מטרתו של המדד, היא לבדוק האם המודל עקבי על קבוצת ווריאציות של אותו רעיון.

הממצא המרכזי

כל המודלים שנבדקו ירדו בביצועים, אפילו כשהשינויים היו קטנים מאוד. הירידה הייתה תלויה מודל, בטווח הנע בין 4% - 20%

כלומר - אפילו החלפת מילים מינימלית, שלא משנה את ההיגיון הבסיסי, עדיין פוגעת משמעותית במודלי NLI.

ממצא חשוב נוסף - ככל שבדקו יותר variants השייכים לאותה קבוצת reasoning problem, הביצועים המשיכו לרדת.
כלומר - המודלים לא באמת generalize היטב, אלא מצליחים רק בחלק מהניסוחים.

המסר המרכזי של המאמר

מודלי NLI עדיין לא מבצעים generalization אמיתי. גם כאשר משנים רק מילים בודדות, תוך שמירה על אותו reasoning, המודלים נשברים ומאבדים עקביות.