

Transitive Self-Consistency Evaluation of NLI Models Without Gold Labels

הרעיון המרכזי

המאמר בודק האם מודלי NLI עקביים לוגית עם עצמם, גם בלי להשוות את התחזיות שלהם ל - gold labels (התשובות ה"נכונות" שסומנו ע"י בני אדם בדאטהסט).
כלומר, במקום לשאול "האם המודל צדק", החוקרים שואלים "האם המודל שומר על היגיון פנימי בין כמה Inference שונים?"
מדובר באבחנה חשובה כי מודל יכול לטעות - אבל עדיין להיות עקבי לוגית.

ההבדל ממאמר "How Often Errors..."

- מאמר "How Often..." - בודק consistency בין paraphrases של אותו משפט.
 - אם ניסחתי את אותו רעיון אחרת - האם המודל יתנהג באותה הצורה?
- המאמר הנוכחי - בודק consistency לוגי לאורך רצף של מסקנות (Inferences).
 - אם המודל מאמין בכמה קשרים לוגיים - האם כל השרשרת הלוגית נשארת הגיונית ביחד?

הרעיון המרכזי של Transitive Consistency

אם $A \rightarrow B$, וגם $B \rightarrow C$
אז לוגית נרצה שהמודל יבין ש - $A \rightarrow C$

תרומת המאמר

מאמרים קודמים בדקו consistency באמצעות gold labels.
כלומר, הם השוו את התחזיות (predictions) של המודל לתשובות (labels) שסומנו ע"י בני אדם.
מנגד, המאמר הזה אומר - גם בלי לדעת מה התשובה הנכונה, עדיין אפשר לבדוק האם המודל עקבי עם עצמו.

ארבעת חוקי ה - Transitivity שנבדקו

(חוקי גרירה)

- Entailment + Entailment $\rightarrow$ Entailment
 - Entailment + Contradiction $\rightarrow$ Contradiction
 - Neutral + Entailment $\rightarrow$ Not Contradiction
 - Neutral + Contradiction $\rightarrow$ Not Entailment
- אם המודל מפר אחד מהחוקים האלו - הוא נחשב inconsistent.

הממצא המרכזי

כל המודלים שנבדקו (BART, RoBERTa, DeBERTa, ModernBERT) הראו inconsistencies משמעותיות. כלומר - המודלים לעיתים נתנו תחזיות, שלא היו עקביות לוגית אחת עם השנייה.
ממצא חשוב נוסף - החוקרים גילו שהמודלים מתקשים במיוחד כאשר שרשרת ה - reasoning כוללת contradiction (שלילה, סתירה. ההפך מ entailment).

המסר המרכזי של המאמר

המאמר מראה שאפשר לבדוק consistency, גם בלי:

- gold labels
- annotation אנושי
- datasets יקרים

וזה מאפשר לבצע evaluation אוטומטי וזול יותר.

בנוסף, המאמר מראה כי מודלי NLI יכולים להיראות מדויקים, אבל עדיין להפר לוגיקה בסיסית כאשר בודקים consistency לאורך כמה צעדי inference.