

Improving LLM Final Representations with Inter-Layer Geometry

הרעיון המרכזי של המאמר

המאמר יוצא נגד ההנחה המקובלת ב- LLMs, שבה משתמשים רק ב- final layer representation לצורך prediction.

החוקרים טוענים שמידע חשוב עבור semantic understanding ו- reasoning מפוזר לאורך שכבות שונות במודל, ולכן שימוש רק בשכבה האחרונה גורם לאיבוד מידע.

מה המאמר מציע?

במקום לבחור רק final layer או רק best layer, המאמר מציע לאפשר לכל שכבות ה- LLM "לתקשר" ביניהן, באמצעות Graph Neural Network (GNN).

כל Layer במודל הופך ל- Node בגרף, וה- GNN לומד כיצד לשלב מידע מכל השכבות ל- representation סופי טוב יותר.

הגישה הטובה ביותר במאמר

הגישה שהשיגה את הביצועים הטובים ביותר הייתה **Cayley-Encoder**.

במקום לחבר כל שכבה לכל שכבה אחרת (Fully Connected, שגם נבדקה), המודל משתמש ב- Cayley Graph - מבנה מתמטי sparse ויעיל, שמאפשר communication מהיר בין שכבות, בלי העלות החישובית הגדולה של Fully Connected Graph.

המאמר הראה ש- Cayley-Encoder השיג תוצאות טובות יותר כמעט בכל המשימות, עם פחות זיכרון, פחות פרמטרים, ופחות סיכון ל- overfitting.