

Project Subject & Methodology

Lidor Mashiach – 209280098

Romy Richter - 212876551

רקע

NLI, Natural Language Inference, היא משימה שבה מציגים למודל הנבחן 2 משפטים, ועל המודל להחזיר את טיב הקשר הלוגי בין 2 המשפטים.

- **Premise** – זהו המשפט הראשון, "המקורי", העובדה הנתונה.
 - **לדוגמה** – "הילד ישן"
- **Hypothesis** – משפט נוסף שבדקים ביחס ל – Premise.
 - **לדוגמה** – "הילד נח"

המודל צריך לקטלג את טיב הקשר, כאחד מבין האפשרויות הבאות :

- **Entailment** – קשר האומר כי המשפט השני (Hypothesis) **נובע** מהמשפט הראשון (Premise).
 - **Contradiction** – קשר האומר כי המשפט השני **סותר** את המשפט הראשון.
 - **Neutral** – אין קשר הכרחי בכיוון אף אחד. ה - Hypothesis לא נובע מה - Premise, אבל גם לא סותר אותו.
- חשוב - Neutral** הוא נובעת מחוסר קשר חד ערכי בין המשפטים, ולא מחוסר ידע של המודל. אין כאן טעות של המודל, זו פשוט המציאות הלוגית. ולכן קטגוריה זו לא צפויה להשפיע על המחקר שלנו, כפי שיוסבר בהמשך.

משימת ה - NLI נחשבת לאחת ממשימות הליבה בתחום ה - **NLU**, Natural Language Understanding (הבנת שפה טבעית). הרעיון הוא שאם מודל יכול לקבוע קשרים לוגיים בין משפטים בצורה אמينة, אזי שהוא "מבין" את השפה ברמה מסוימת.

הבעיה הקיימת – מה שכבר ידוע מסקירות הספרות

כל המאמרים שנסקרו הראו את אותה תמונה: מודלי NLI מגיעים לציונים גבוהים מאוד על benchmark סטנדרטי, אבל נשברים ברגע שמשנים משהו קטן בניסוח.

לדוגמה:

המודל ענה נכון על :

- **Premise** - The boy is sleeping
- **Hypothesis** - The boy is resting
- **קשר** - Entailment

כעת, יוצרים **Paraphrase** של ה - Hypothesis - **ניסוח אחר עם אותה משמעות לוגית בדיוק**:

- **Paraphrase** - The boy is napping - קשר לוגי זהה ל - Hypothesis.

כעת, משווים את ה - Premise המקורי, ל - Paraphrase המקורי, ומודל ה - NLI משנה תשובתו ל - Contradiction, למרות שהמשמעות הלוגית זהה לחלוטין.

תופעה זו נקראת **חוסר עקביות סמנטית, Semantic inconsistency** - הנטייה של המודל לשנות תחזית בגלל שינויי ניסוח שלא אמורים לשנות את המשמעות.

מה שידוע עד כה בקהילה המחקרית - התופעה קיימת, תועדה עשרות פעמים, על מודלים ודאטה סטים שונים.

מה שלא ידוע - איפה בדיוק, בתוך המודל, הבעיה נוצרת. המחקרים הקיימים מדדו את התוצאה בלבד. אך אף אחד לא פתח את ה - Black Box ושאל : **באיזה שלב של העיבוד הפנימי המודל כבר "אבד"?**

הרעיון המחקרי שהוחלט – DkNN, Depp kNN

שיטה שפותחה במקור לתחום עיבוד תמונה. אנחנו מציעים להתאים אותה לעולם NLI.

מודל שפה כמו BERT מעבד קלט דרך שכבות Encoders רבות. כל שכבה מייצרת ייצוג (**representation**), וקטור מספרי שמתאר את הקלט כפי שהמודל "רואה" אותו בנקודה הזו של העיבוד. בשכבה הראשונה ה- **representation** פשוט יחסית. ככל שמתקדמים בשכבות, ה- **representation** הופך מופשט יותר ומבטא הבנה עמוקה יותר.

DkNN שואל בכל שכבה - מי מדוגמאות האימון שראה המודל בעבר (*Premise : Hypothesis*) הכי דומות לדוגמה הנוכחית בסט המבחן (*Premise : Paraphrase*), ברמת ה- **representation** של השכבה הזו?

- אם בכל השכבות השכנים הקרובים שייכים לאותה קטגוריה כמו התשובה הסופית - **התחזית אמינה**. זה נקרא **credibility גבוה** (מדד אמינות המוזכר במאמר ה- DkNN).
- אם בשכבות מסוימות השכנים מצביעים לכיוון אחד, ובסוף המודל ענה אחרת - יש **סתירה פנימית**. זה נקרא **credibility נמוך**.

DkNN לא שואל רק "מה המודל חשב?", אלא "כמה עקבית הייתה החשיבה שלו לאורך הדרך?"

Credibility - הגדרה מדויקת

Credibility מחושב כך - עבור כל שכבה :

- מוצאים את K השכנים הקרובים ביותר (לפי מרחק קוסינוס בין הוקטורים).
- בודקים את ה- label של כל אחד מ- K השכנים.
- צוברים את הספירות מכל השכבות יחד.
- Credibility של label מסוים = כמה מהשכנים הכוללים (מכל השכבות) תומכים בו.

לדוגמה :

- יש 12 שכבות ב- BERT-base, ו- $K=10$ שכנים בכל שכבה.
 - סה"כ 120 "קולות".
- אם :
 - 100 מתוכם תומכים ב- entailment והמודל אמר entailment, credibility גבוה.
 - 70 תומכים ב- contradiction אבל המודל אמר entailment, credibility נמוך.

כיצד בוחרים K

- מריצים על validation set עם ערכי K שונים (למשל: 5, 10, 20, 50).
- בוחרים את ה- K שבו הקשר (קורלציה) בין credibility נמוך לבין שגיאות בפועל הוא החזק ביותר.
- כל מודל מקבל K משלו - מכיוון שגדלי מודלים שונים ומרחבי ייצוג שונים מגיבים אחרת.
- כל שכבה מקבלת את אותו K בתוך מודל נתון.

שאלת המחקר המרכזית

עד כה, DkNN לא יושם על מודלי NLI. אנו מציעים לעשות זאת לראשונה. ולכן **שאלת המחקר הראשית** תהיה :

- האם חוסר עקביות סמנטית של מודלי NLI, מתבטא כבר ברמת הייצוגים הפנימיים של המודל, ולא רק ברמת הפלט הסופי ?

משאלה זו, ניתן לגזור את **שאלות המחקר משניות** :

- האם יש קשר בין רמת Credibility נמוכה לבין חוסר עקביות סמנטית ?
- אם כן — באיזה אזור של השכבות הבעיה בולטת יותר, ומה ניתן להסיק מכך?
- האם ניתן ב- Credibility כסיגנל לשיפור ממוקד של המודל ?

מתודולוגיה – סד"פ מסודר בסוף

שלב א' – אבחון מקור הבעיה בעזרת DkNN

- **תנאי בסיס** - כל Paraphrase חייב לקבל את אותה תשובה נכונה כמו ה - Hypothesis המקורי. אחרת, שינוי תשובה הוא מוצדק ואין מה לחקור. תנאי זה נבדק לפני הניסוי.
- **מה בודקים ועל מה** :
 - **מודלים** - אלו שהופיעו הכי הרבה פעמים בסקירות הספרות.
 - RoBERTa-large, DeBERTa-large, BERT-base, BART-large
 - **דאטה סטים** - SNLI, MNLI, ANLI
 - SNLI בנוי מתיאורי תמונות, MNLI בנוי מ-10 ז'אנרים שונים (עיתונות, שיחות, חוקים וכו'). אין ביניהם חפיפה של רשומות.
 - הסיבה לבחור דווקא את השלושה - הם הדאטה סטים שהופיעו הכי הרבה בכל הסקירות, והם מייצגים רמות קושי עולות — SNLI הכי פשוט, MNLI בינוני, ANLI הכי קשה (נבנה adversarially). זה נותן תמונה רחבה.
 - אין לאחד את הדאטה סטים לכדי דאטה סט אחד. כל דאטה סט מייצג אוכלוסייה שונה של משפטים. אם מאחדים ורואים שיפור, אי אפשר לדעת אם השיפור הגיע מ - SNLI, MNLI, או ANLI. הפרדה נותנת תמונה עשירה יותר ו-soundness גבוה יותר.
 - **דוגמאות שנכנסות לניסוי** - רק דוגמאות שהמודל ענה עליהן נכון מלכתחילה בשלב ה - Hypothesis : Premise. כך מבטיחים שאנחנו מודדים רגישות לניסוח, לא סתם טעויות רגילות.
 - **שלושת הסוגים של תוצאות אפשריות** (לאחר קבלת תשובת ה - Premise : Paraphrase) :
 - **המודל נשאר עקבי (תשובה זהה)** - המודל סיפק שטיב הקשר של Premise : Paraphrase **זהה** לזה של Hypothesis : Premise, בדיוק כמו שצריך.
 - במקרה הזה, נריץ את DkNN כדי למדוד את רמת האמינות (Credibility).
 - **הציפיה** - רמת ה - Credibility תהיה גבוהה. מקרים אלו ישמשו כ - Baseline להשוואה.
 - **המודל שינה את תשובתו (המודל טעה)** - המודל סיפק שטיב הקשר של Premise : Paraphrase **שונה מזה** של Hypothesis : Premise, וזו טעות.
 - במקרה הזה, נריץ את DkNN כדי למדוד את רמת האמינות (Credibility).
 - **הציפיה** - רמת ה - Credibility תהיה נמוכה יותר מאשר במקרה א'.
 - **המודל שינה את תשובתו, אך השינוי מוצדק** - מקרים אלו לא אמורים להתקיים בכלל, כי תנאי הבסיס הוא ש - Paraphrase מקיים קשר לוגי זהה למשפט ה - Hypothesis

שלושה מדדים עיקריים

1. **Consistency, עקביות התשובה** - זהו הממד הפשוט ביותר, ומשמש כנקודת מוצא. עבור כל זוג (Hypothesis מקורי וה - Paraphrase שלו), שואלים : האם המודל נתן את אותה התשובה לשניהם?
 - a. כן ← consistent
 - b. לא ← inconsistent
- מחשוב זה נגזרים ארבעה מדדים כמותיים:**
- **Relaxed Fooling Rate** - אחוז הזוגות שבהם הייתה אי-עקביות כלשהי.
 - מדד מהמאמר הראשי.
 - **Strict Fooling Rate** - אחוז הזוגות שבהם התשובה התהפכה לגמרי (entailment ↔ contradiction).
 - מדד מהמאמר הראשי.
 - **PC, Paraphrastic Consistency** - ההסתברות שמודל יישאר עקבי על זוג נתון.
 - מדד זה בא מהמאמר "How Often Are Errors"
 - **PA, Pattern Accuracy** - עקביות על קבוצה של מספר Paraphrases לאותו Hypothesis, לא רק זוג אחד. מחמיר יותר מ - PC
 - מדד זה בא מהמאמר MERGE
 - מדד זה מצריך לבצע כ - 5 paraphrases לכל Hypothesis

חשוב להבהיר – בחישובי ה – Consistency כוללים את כל שלוש הקטגוריות, כולל Neutral. כלומר, אם Premise : Hypothesis קיבלו Neutral ו Premise : Paraphrase קיבלו גם הם Neutral, אז זה נחשב כ – **Consistent**. אם התשובה השתנתה לכל כיוון כלשהו – אז זה **Inconsistent**. מכאן נגזר ההבדל בין מדד ה – Relaxed לבין מדד ה – Strict. **Relaxed** סופר כל שינוי תשובה, כולל מעבר מ – Neutral ל – Neutral, ומעבר מ – Neutral ל – Contradiction. **Strict** סופר רק היפוך מוחלט Contradiction ↔ Entailment.

2. **Layer Distance, מרחק וקטורי בין ייצוגים** – כאן מתחילים לפתוח את ה – Black Box. בכל שכבה i של המודל, מוציאים את ה – representation של ה – Hypothesis המקורי ואת ה – representation של ה – Paraphrase, ומחשבים מרחק קוסינוס ביניהם. **זה לא קשור לשכנים** – זה ישירות בין שני הווקטורים. עושים זאת **לכל שכבה בנפרד**, ומקבלים פרופיל מרחק לאורך כל המודל.

a. "מספיק רחוק" לא נקבע שרירותית – מחשבים את התפלגות המרחקים על כל הדוגמאות ה – consistent (שבהן המודל לא שינה תשובה), ודוגמה שהמרחק שלה עולה על ממוצע זה ועוד סטיית תקן אחת נחשבת "זזה". הסף נגזר מהדאטה עצמו.

b. המרחק מחושב הן על זוגות consistent והן על זוגות inconsistent. ההשוואה בין שתי הקבוצות היא הממצא – אם זוגות inconsistent מראים מרחק גדול יותר בשכבות מסוימות מאשר זוגות consistent – אותן שכבות הן המועמד לאזור הבעיה.

3. **Credibility, מדד אמינות החיזוי** – זהו המדד המרכזי של DkNN.

a. **מתוך ה – train set** – עבור כל Hypothesis ב – train set, שומרים את ה – representation שלו **בכל שכבה**. כך מתקבל מאגר ייצוגים עם labels ידועים.

b. **Test Set** – עבור דוגמת (Premise : Paraphrase), מחפשים בכל שכבה את K השכנים הקרובים ביותר במאגר שיצרנו בשלב a, לפי מרחק קוסינוס. צוברים את כל השכנים מכל השכבות ובודקים את ה – label שלהם.

לדוגמה:

- i. נגדיר מודל עם:
 - (a) 12 שכבות
 - (b) וערך $k=10$
 - (c) משמע, בעבור כל דוגמת test אנו בוחנים 120 שכנים בסה"כ.
- ii. אם המודל אמר **entailment** ו – :
 - (a) 95 מתוך 120 שכנים שייכים ל – entailment
 - (i) Credibility גבוה.
 - (b) רק 40 מתוך 120 שכנים אמרו entailment
 - (i) Credibility נמוך. גם אם התשובה הנכונה היא entailment.
- c. בודקים credibility הן על ה – Hypothesis המקורי, והן על ה – Paraphrase שלו. ההשוואה בין השניים חושפת את מקור הבעיה:
 - i. **Credibility של ה – Paraphrase ירד ביחס ל – Hypothesis** – הייצוג של ה – Paraphrase נמצא באזור שה – Training Set אינו מכסה כראוי. הייצוג באזור שלו דליל.
 - (a) **משמעות** – המודל לא למד לייצג וריאציות סמנטיות כ"אותו הדבר" ברמה הלוגית
 - (b) **מסקנה** – מדובר בבעיית הכללה ברמת הייצוג הפנימי. המודל לא ראה מספיק דוגמאות באזור הייצוג הזה, ולכן טעה.
 - (c) **פתרון אפשרי בשלב ב' של הניסוי** – להוסיף paraphrases ממוקדים לאזורים הדלילים
 - ii. **Credibility של ה – Paraphrase עלתה** – ה – Paraphrase נפל לאזור ייצוגי שונה עם תמיכה חזקה ל – label השגוי.
 - (a) **משמעות** – הניסוח החדש (paraphrase) נראית למודל בדיוק כמו דוגמאות מקטגוריה אחרת.
 - (b) **מסקנה** – מדובר בבעיית ייצוג – המודל איגד ניסוחים מסוימים עם Label שגוי.
 - (c) **פתרון אפשרי בשלב ב' של הניסוי** – fine tuning עם דוגמאות שמתקנות את האיגוד השגוי. גם כאן paraphrases ממוקדים יכולים לעזור, אבל הם צריכים לשבור את האיגוד השגוי – לא רק להוסיף דוגמאות. מורכב יותר מבעיית הכללה.

- iii. **Credibility נשארה זהה בערך** – הייצוג לא השתנה.
 (a) אם גם התשובה לא השתנתה – תקין.
 (b) אם התשובה כן השתנתה למרות credibility זהה :
 (i) **משמעות** – הייצוג הפנימי זהה, אך ה – Classifier הסופי החליט אחרת.
 (ii) **מסקנה** – מדובר בבעיית Classifier, ולא בבעיית הבנה.
 (iii) **פתרון אפשרי בשלב ב' של הניסוי** - fine tuning על ה-classifier עצמו, או regularization

- d. **הערה על Hyper-Parameter K**
 לכל צמד של מודל : דאטה סט, יש ערך K משלו.
 ערך ה – K נבחר כזה שמייצר את הקורלציה הגבוהה ביותר בין Credibility נמוך לבין inconsistency בפועל. יש לבחון את הקורלציה על ה – Validation Set.
 נבדוק כמה ערכים אפשריים – לדוגמה 5, 10, 20, 50.
 e. **לגבי הרף שמגדיר "Credibility נמוך"** – לא קובעים סף מוחלט מראש.
 עובדים עם ההפרש **CredibilityParaphrase – CredibilityHypothesis**
 i. **הפרש** שלילי וגדול - מעיד אמינות הסיווג של ה – Paraphrase ירדה ביחס לאמינות הסיווג של ה – Hypothesis שלו.
 ii. **"הפרש גדול"** נקבע לפי התפלגות כל ההפרשים : הפרש שנמצא מתחת לממוצע ההפרשים פחות סטיית תקן של ההפרשים נחשב כחריג.
 (a) הסף נגזר מהדאטה של כל צמד מודל + דאטה סט בנפרד.

המטרה של שלב א' – שלב האבחון

אחרי שיש credibility לכל דוגמה, בודקים: האם דוגמאות שה – Hypothesis המקורי שלהן קיבל ערך Credibility נמוך, הן אלו שהמודל שינה תשובה כשהציגו להן Paraphrase ?
 זה ה – finding המרכזי של שלב א'.
 אם הקורלציה חיובית ומובהקת – הרי ש – DkNN מזהה מראש את הדוגמאות הפגיעות, עוד לפני שראינו את ה – Paraphrases.

שלב ב' – נגזר מתוך תוצאות ה Credibility

סיכום המחקר – Flow סופי – סד"פ מלא

1. נגדיר **X** כקבוצת המודלים הבאה :
 - a. RoBERTa-large, DeBERTa-large, BERT-base, BART-large
2. נגדיר **Y** כקבוצת הדאטה-סטים הבאה :
 - a. SNLI, MNLI, ANLI
3. מאמנים כל אחד ממודלי קבוצת X בכל אחד מהדאטה סטים של Y.
4. עבור כל זוג של (x,y) מוצאים את ה **K האופטימלי** – ה K המביא את ערך הקורלציה הגבוה ביותר בין Credibility נמוך לבין Inconsistency על ה - Validation Set
 - a. **Credibility** נמוך מוגדר כהפרש **CredibilityParaphrase – CredibilityHypothesis**
 - i. **הפרש שלילי וגדול** - מעיד על כך שאמינות הסיווג של ה - paraphrase ירדה ביחס לאמינות הסיווג של ה - Hypothesis שלו.
 - ii. **"הפרש גדול" נקבע** לפי התפלגות כל ההפרשים : הפרש שנמצא **מתחת לממוצע ההפרשים פחות סטיית תקן** של ההפרשים נחשב כחריג.
5. עבור כל **רשומת אימון של Premise: Hypothesis** שהמודל סיווג בשלב האימון את הקשר הלוגי ביניהם בצורה נכונה, אנו ממשיכים איתה לשלב הבא.

משמע, כל רשומה שכבר בשלב הזה המודל לא הצליח למפות כראוי בזמן האימון, אנו זונחים בשלב הזה, ולא יוצרים עבורה Paraphrase לשלב ה - Test.
6. עבור כל קומבינציה של (x,y) ניצור **דאטה סט חדש המייצג את הייצוגים הווקטוריים** של כל אחת מה - Hypotheses. כל Hypothesis מקבלת **ייצוג נפרד בעבור כל שכבה במודל X**.
 - a. לכל ייצוג שכזה יש לשמור גם את הסיווג שלו - (Entailment, Contradiction, Neutral) ישמש אותנו בשלב ה - Credibility.
 - b. הסיווג של כל ייצוג מהווה כסיווג הסופי של ה - Hypothesis שאליו שייך הייצוג.
7. יוצרים Paraphrases לכל Hypothesis שנשארה עד שלב זה (שהמודל צדק בסיווג בשלב האימון).
 - a. אם רוצים את מדד ה - PA, אז צריך כ - 5 פרפרזות לכל Hypothesis כאלו השומרות על אותו קשר לוגי עם ה - Hypothesis.
8. **עכשיו ניתן להתחיל את ה - Test. ה - Test הוא העברת Premise: Paraphrase במודל ה - X**.
 - a. עבור כל Paraphrase - שומרים את הייצוג הפנימי שלו - בכל אחת משכבות המודל X.
 - i. לכל ייצוג שכזה יש לשמור גם את הסיווג שלו - (Entailment, Contradiction, Neutral) ישמש אותנו בשלב ה - Credibility.
 - ii. הסיווג של כל ייצוג מהווה כסיווג הסופי של ה - paraphrase שאליו שייך הייצוג.
9. **עכשיו מתחילים לחשב מדדים :**
 - a. **מדד Consistency:**
 - i. אם הסיווג של Paraphrase של Premise: Paraphrase (ונכון) לזה של Premise: Hypothesis
 - (a) אז +1 למצבור ה - Consistency.
 - (b) אחרת, +1 למצבור ה - Inconsistency.
 - ii. **לאחר** שחישבנו את ה Consistency של כל זוג - (x,y) נגזור מזה 4 מדדים שהופיעו בסקירות הספרות :
 - (a) מדד **Relaxed** - מאמר ראשי
 - (b) מדד **Strict** - מאמר ראשי
 - (c) מדד **PC** - מאמר How Often Errors
 - (d) מדד **PA** - מאמר MERGE
 - (i) זה רק אם החלטנו לייצר 5 Paraphrases לכל Hypothesis

b. מדד Layer Distance

- i. מחשבים את המרחק בין הייצוגים של ה - Paraphrase לבין אלו של ה - Hypothesis, בכל אחת מהשכבות. המרחק מחושב ע"י מרחק ווקטורי (קוסינוס).
- ii. שומרים את תוצאות המרחקים - תוך שמירת מידע על :
 - (a) x
 - (b) y
 - (c) Consistent / Inconsistent – האם תוצאת הסיווג הסופית השתנתה או לא
 - (d) Layer Number
- iii. סוכמים את מרחקי כל שכבה - ומחשבים את המרחק הממוצע של כל שכבה.
ממוצע נפרד ל - Consistent ול - Inconsistent
 - (a) בצורה הזו, נוכל לראות מה הממוצע של המרחק בין הייצוגים של ה - Paraphrase וה - Hypothesis בכל שכבה.
 - (b) ההפרדה בין ממוצעי Consistent ל - Inconsistent תעזור לבדוד את ההבנה של האם המרחקים נהיים גדולים יותר כאשר המודל טועה (Inconsistent) בסיווג
ה - Paraphrase
(i) הציפיה - שכן.
 - (c) **בנוסף**, בעזרת ההפרדה לפי שכבות נוכל לבנות **גרף מוחלק** המראה את השכבות שבהן בממוצע המודל מתחיל להוביל למרחק ייצוגי גדול.
(i) **אם בשכבות התחתונות -** הרי שמדובר **בבעיית ייצוג**.
המודל מהתחלה קודד את ה - Paraphrase למקום מרוחק. הוא לא מבין כי מדובר בווריאנט של ה - Hypothesis השומר על אותו קשר לוגי.
(ii) **אם בשכבות העליונות -** הרי שמדובר **בבעיית Classifier**.
המודל קודד את ה - Paraphrase קרוב ל - Hypothesis לאורך רוב הדרך, כולל שכבות ה - Reasoning האמצעיות. הפירוד קורה רק בסוף, בשכבות שאחראיות על קבלת ההחלטה הסופית. המודל "הבין" את ה Paraphrase נכון, אבל טעה בשלב הסיווג בלבד.
(iii) **אם בשכבות האמצעיות -** הרי שמדובר **בבעיית Reasoning**.
המודל קודד את ה - Paraphrase יחסית קרוב ל - Hypothesis בשכבות התחתונות - הרי שהבין שהן שייכות לאותו אזור. אך עם המעבר בשכבות, הסקת מסקנות שגויה הובילה לקידוד לקוי, ושלחה אותו לאזור מרוחק.
(d) **על כל גרף -** נוכל להציג קו אופקי המראה איפה עובר הקו של "החל מנקודה זו, המרחק בין ה - Hypothesis לבין ה - paraphrase גדול מידי".
(i) **המרחק התקין** יקבע ע"י זוגות ה Paraphrase : Hypothesis שהיו Consistent בלבד (כדי לא להכניס טעויות ורעש לחישוב).
יחושב ע"י **המרחק הממוצע + סטיית התקן**. מרחק גדול מזה יחשב כגדול מידי וחריג.

c. מדד Credibility

- i. מדד אמינות החיזוי, נגזר ממאמר ה - DkNN.
- ii. כפי שנאמר קודם לכן :
 - (a) **Credibility נמוך** מוגדר כהפרש
 $Credibility_{Hypothesis} - Credibility_{Paraphrase}$
 - (i) **הפרש שלילי וגדול** - מעיד על כך שאמינות הסיווג של ה - paraphrase ירדה ביחס לאמינות הסיווג של ה - Hypothesis שלו.
 - (ii) **"הפרש גדול" נקבע** לפי התפלגות כל ההפרשים : הפרש שנמצא מתחת לממוצע ההפרשים פחות סטיית תקן של ההפרשים נחשב כחריג.
הסף נגזר מהדאטה של כל צמד מודל + דאטה סט בנפרד.
 - iii. **בנוסף**, בשלב זה נשתמש **במאגר הייצוגים** של ה - Hypothesis ושל ה - Paraphrases כפי שיצרנו בשלבים 6 ו - 8.
 - iv. עבור **כל דוגמה ב - Test Set** (ה - Paraphrase), בכל שכבה מחדש :
 - (a) בודקים מי הם ה K שכנים הקרובים ביותר (אותם שכנים, הם ה - Representations של ה - Hypothesis שיצרנו בשלב 6).
 - (b) עבור כל דוגמה של ה - Test - מונים כמה שכנים תמכו בתוצאת הסיווג הסופית של הדוגמה, וכמה לא.
 - (c) **ערך ה - Credibility יהיה ככמות התומכים בסיווג הסופי חלקי כל השכנים שנלקחו בחשבון :**
 - (i) **כמות השכנים שנלקחים בחשבון** $= k * \text{כמות השכבות במודל}$
 - (ii) **התומכים** = כל שכן שהלייבל שלו שווה ערך לסיווג הסופי של הדוגמה, לא משנה אם הסיווג של הדוגמה ב Test הוא טעות או לא.
 - v. **מחשבים ערכי Credibility** באותו האופן גם **לכל ה - Hypotheses** (רק אלו שבשלב האימון החזירו סיווג נכון).
 - vi. עכשיו, נוכל להשוות את אמינות הסיווגים.
אם :
 - (a) $mean(Credibility_{Hypo}) - std(Credibility_{Hypo}) > mean(Credibility_{Paraphrase})$
אז - האמינות ירדה ב - Paraphrases.
הייצוג של ה - Paraphrase נמצא באזור עם מעט דוגמאות ב - Representations .
(i) **מדובר בבעיית הכללה.**
 - (b) $mean(Credibility_{Hypo}) + std(Credibility_{Hypo}) < mean(Credibility_{Paraphrase})$
אז - האמינות עלתה ב - Paraphrases.
הייצוג של ה - Paraphrases נמצא באזור ייצוג שונה המתאים ל - Label שונה ושגוי.
(i) **מדובר בבעיית ייצוג.**
 - (c) $mean(Credibility_{Hypo}) - std(Credibility_{Hypo}) < mean(Credibility_{Paraphrase}) < mean(Credibility_{Hypo}) + std(Credibility_{Hypo})$
אז - האמינות נשארה בטווח הנורמלי של ה - Hypothesis
(i) במצב כזה - **הייצוג לא השתנה** מעבר לטווח הנורמלי (סיווג סוג הבעיה בהמשך).

שלב ב' - מופיע בעמוד הבא

מה ניתן לעשות בשלב ב' – תלוי ב – Credibility

- **אם גילינו שאמינות ה - Paraphrases ירדה ביחס לאמינות ה - Hypotheses**
 - בעיית הכללה
 - נוכל להבין כי חסרות דוגמאות מתאימות בסט האימון לאזורים אלו.
 - ניצור עוד פרפרזות ל - Hypothesis - ונכניסן לסט האימון .
 - **חשוב –** נוסיף את הפרפרזות החדשות לסט האימון ולא לסט המבחן. סט המבחן צריך להישאר זהה, כדי שהבדיקה החוזרת תהיה אמינה.
 - **חשוב –** ניצור פרפרזות חדשות אך ורק להיפותזות שה - Paraphrase המקורית שלהן הראתה ירידה ב - Credibility. הוספת פרפרזות חדשות לכל ההיפותזות, גם לאלו שצדקו – תיחשב כטיפול עיוור ותיוחס כאילו לא שיפרנו את נקודות החולשה של המודל.
 - לא נאמן מחדש מאפס - מספיק Fine Tuning על התוספים.
 - **הציפיה -** שזה התרחיש שנראה, וכי Fine Tuning ממוקד יעלה את מדד האמינות של הפרפרזות.
 - **חשוב -** לאחר ביצוע Fine Tuning והוספת Paraphrases לסט האימון, יש לבנות את מאגר הייצוגים מחדש. המודל השתנה, ולכן הייצוגים הישנים אינם תקפים עוד.
 - **חשוב –** נשווה את התוצאות לשני Baselines :
 - ◆ המודל המקורי ללא כל שינוי.
 - ◆ מודל שקיבל אותה כמות של Paraphrases, אך שנבחרו באקראי ולא לפי Credibility.
 - רק אם הגישה הממוקדת עולה על ה - Baseline האקראי, ניתן לטעון כי ה - Credibility כסיגנל הוא אינפורמטיבי ושימושי, ולא רק כמות הדאטה שהשפיעה.
 - **במידה וביצענו את התהליך הנ"ל –** יש לבצע חישובי מדדים מחדש כדי לבחון את ההבדלים.
- **אם גילינו שהאמינות של ה - Paraphrases עלתה ביחס לאמינות ה - Hypothesis**
 - בעיית ייצוג
 - מודלי ה - NLI מציגים תוצאות פחות טובות של ה - Paraphrases עקב בעיית ייצוג פנימית. זו מסקנה חשובה לקהילה המדעית (מעבר לזה אין מה לנסות, כל ניסיון יהיה "חסר בסיס").
- **אם גילינו שהאמינות של ה - Paraphrases נשארת בערך באותו המקום כמו אמינות ה - Hypotheses**
 - אם הרוב המוחלט של ה - Paraphrases יהיו Consistent - הרי שהכל טוב **ואין בעיה**.
 - אם הרוב המוחלט של ה - Paraphrases יהיו Inconsistent - למרות שהאמינות לא השתנתה - הרי שמדובר **בבעיית Classifier** .
 - ניתן לנסות רגולריזציה או ניסויי Fine Tuning נוספים, אבל הציפייה שלא יהיה שיפור ניכר. אולי פשוט המודל לא מתאים למשימה.

חשוב לציין ש... ייתכן התרחיש בו כי בשלב הסקת המסקנות מ - **Layer Distance**, נסיק כי מדובר בבעיית Classifier, ואילו בשלב הסקת המסקנות מ - **Credibility** נסיק כי מדובר בבעיית generalization.

זה הגיוני כי שני המדדים מודדים דברים שונים:

- **Layer Distance** מודד איפה הייצוגים מתפצלים ומתרחקים זה מזה (באיזו שכבה).
- **Credibility** מודד לאן הייצוג של ה - Paraphrase נוחת ביחס לדאטה האימון.

אפשר שהפיצול קורה מאוחר, אבל הנחיתה היא באזור שגוי.

המסקנה במקרה כזה - הבעיה מורכבת ואינה חד-ממדית. גם הייצוג וגם ה-Classifier תורמים לשגיאה. זה מחזק את הטענה שחוסר עקביות סמנטית לא נובע ממקור יחיד.